

当 LLM 吞噬一切

2023–2026 年 AI 研究全景观察与反思

——基于 9 大顶会/期刊论文的跨领域趋势分析

2026 年 7 月 16 日

数据来源：ICML / IEEE S&P / USENIX (Security, OSDI, ATC, NSDI) / SIGCOMM / INFOCOM /
NDSS / TDSC / ACM DL

覆盖时间：2023–2026 年 论文总量：500+ 篇

1 引言：一条分水岭

2023 年是一个分水岭。这一年之前，不同领域的顶级会议还各自为战：安全会议讨论后门攻击和差分隐私，系统会议关注分布式训练和 GPU 调度，网络会议研究拥塞控制和数据平面优化。它们之间当然有交集，但交集很小。

ChatGPT 的出现改变了一切。

当我把 9 个顶级会议/期刊的论文摊开，试图找出 2023–2026 年间的研究趋势时，一个无法回避的事实浮现出来：**大语言模型（LLM）正在吞噬计算机科学的每一个子领域**。这不是比喻，而是对 500 多篇论文题目和摘要逐一审视后的统计事实。

LLM 不是 AI 的一个子方向。

LLM 是 AI 的一个时代。

本文尝试回答几个问题：LLM 为什么能吞噬一切？在它吞噬的过程中，哪些方向被消灭了，哪些被重塑了，哪些反而获得了新生？不同领域之间的「温差」有多大？以及——这对研究者意味着什么？

2 LLM：吞噬一切的逻辑

2.1 不是「又多了一个 topic」，而是「所有 topic 都被重写」

在 IEEE S&P 这个安全领域的旗舰会议上，2023 年还没有一篇专门针对 LLM 的论文。但到了 2025 年，LLM Security 已经成为一个**独立的完整 session**——从越狱攻击（MASTERKEY、SneakyPrompt）、提示注入（Fun-tuning）、到 LLM 应用商店安全（GPTracker），覆盖了整个攻击面。

在 SIGCOMM 这个网络领域的顶会上，2024–2025 年间 LLM 训练和推理的基础设施论文爆发式增长：GPU 通信调度（Crux）、KV Cache 网络传输（CacheGen）、光交换网络支撑 LLM 训练（InfiniteHBD）、LLM 辅助网络运维（BiAn）。网络不再只是「传输数据包」，而是「传输智能」。

在 NSDI 2026 上，LLM 相关论文占据了**大幅版面**：训练、推理、调度、KV Cache 管理、Agent 服务化，甚至连 session 名称都变成了「All Your Networks Are Belong to ML」这样的宣言。

思考

LLM 之所以能「吞噬一切」，不是因为学术界跟风，而是因为它确实改变了每个领域的核心约束。安全的攻击面变了（从 DNN 到 LLM），网络的瓶颈变了（从带宽到 GPU 通信），系统的优化目标变了（从吞吐量到 TTFT/TPOT）。**问题是真问题，不是蹭热点。**

3 架构之争：当 Transformer 不再是唯一的答案

如果说 2023 年的共识是「Transformer is all you need」，那么 2026 年的图景要复杂得多。三个挑战者正在从不同方向撼动 Transformer 的统治。

3.1 扩散语言模型：年度最大黑马

ICML 2026 的**两项杰出论文奖全部颁给了扩散模型研究**——这是近年来首次单个范式包揽最高奖项。清华和阿里合作的《The Flexibility Trap》证明了一个反直觉的结论：扩散语言模型「任意顺序生成」的灵活性，在推理任务上反而是个陷阱——模型会绕过高不确定性的关键 token，导致解空间坍塌。MIT 的《High-Accuracy Sampling》则从理论上证明扩散模型可以以指数级优势超越自回归模型。

思考

扩散模型从图像生成杀入语言建模，这件事本身就值得玩味。它提醒我们：「主流」不等于「最优」，技术路线的垄断往往只是阶段性均衡。就像十年前 CNN 统治视觉、RNN 统治序列，谁也想不到一个来自机器翻译的注意力机制会颠覆一切。

3.2 Mamba/RWKV：RNN 的复仇

在 2023–2025 年间，CNN 和 RNN/LSTM 在几乎所有顶会上消失——不是「减少」，是「消失」。NDSS、IEEE S&P、USENIX、SIGCOMM、NSDI 的论文题目中，LSTM 和 RNN 的出现次数趋近于零。NSDI 2026 的关键词统计中，CNN/RNN/LSTM/RWKV 的统一计数是 0。

但这并不意味着序列建模不需要高效架构。SSM/Mamba/RWKV 正在走一条完全不同的路：Mamba-3 入选 ICLR 2026 Oral；RWKV 迭代到第 7 代；ACM Digital Library 显示，Hybrid Mamba-Transformer 已经成为新范式。更重要的是，这些架构的 $O(L)$ 推理复杂度天然适合边缘部署——而边缘部署正是 LLM 的下一个战场。

思考

RWKV 至今未出现在 INFOCOM、SIGCOMM、NDSS 等会议上。这是「温差」，也是机会。当一个架构在 ML 社区已经获得认可（ICLR Oral），但尚未渗透到网络/安全社区时，往往意味着蓝海。当然，前提是这个架构确实能解决那个领域的真问题，而不是强行嫁接。

3.3 CNN 和 LSTM：不是死了，是退出了舞台中央

CNN 仍然是计算机视觉底层特征提取的不可替代的工具，但「CNN+」混合架构才是它的生存方式。LSTM 在时序预测等垂直场景仍有应用，但不再是论文标题关键词。这不是说它们没用——而是说，它们不再是论文的「卖点」。在顶会上，你很难靠「我们用 CNN/LSTM 解决了 X 问题」来打动审稿人了。

4 安全：当 AI 自己成为攻击面

4.1 三重迁移：从模型到生态、从数字到物理、从经验到理论

安全领域的变化速度和深度，可能是所有子领域中最剧烈的。

第一重：攻击面从「模型」扩张到「生态」。2023 年的 AI 安全还集中在 DNN 的对抗鲁棒性和后门攻击上。到了 2024–2025 年，攻击面已经扩展到 LLM 应用商店（GPTracker）、训练数据供应链投毒（Poisoning Web-Scale Training Datasets is Practical）、提示版权窃取（Prompt Stealing）、语音克隆检测——安全研究正在从「模型安全」走向「生态安全」。

第二重：攻击从数字域走向物理域。NDSS 2025 出现了 AlphaDog（利用 Alpha 通道的物理世界伪装攻击）、DorPatch（分布式遮挡鲁棒对抗补丁）。安全研究的「真实感」在增强——不再只攻击 ImageNet 分类器，而是攻击自动驾驶、摄像头、助听器。

第三重：从经验走向理论。ICML 2026 上，Northwestern 的 CRAFT 论文发现：即使推理模型给出安全的最终输出，中间推理过程仍可能泄露不安全内容——这被称为「表面安全对齐」（Surface Safety Alignment, SSA）。这不再是一个经验性的「加更多安全数据」的问题，而是一个需要理论解释的深层现象。

思考

这三重迁移指向同一个方向：AI 安全正在从「工程问题」变成「科学问题」。一个成熟的学科，不能只靠「我们又发现了一种攻击」来推动，而是需要理论框架来解释「为什么会有攻击、攻击的本质是什么」。2026 年，我们正在这个转折点上。

4.2 后门攻击的靶子迁移：Vision Transformer 成了新猎物

TDSC 2025–2026 年的数据显示，后门攻击的目标正在从传统 CNN/DNN 快速迁移到 Vision Transformer。Megatron、三重隐蔽后门（空间 + 频域 + 特征域）、多触发器攻击——这些比传统后门攻击精细得多。ViT 的注意力机制给攻击者提供了新的「后门通道」，也带来了更隐蔽的攻击手段。

这提出了一个深层问题：**新架构引入新能力的同时，是否也引入了新的脆弱性？**Transformer 替代 CNN 不是因为「更安全」，而是因为「更强」。但如果「更强」意味着攻击面更大，我们如何权衡？

4.3 LLM 安全：从零到专场的爆发

在 2023–2025 的 IEEE S&P 上，LLM 安全论文从 0 篇增长到一个完整 session。在 NDSS 上也呈现类似曲线。这是一个典型的「研究方向生命周期」的压缩版——通常一个方向从出现到顶级会议有专门 track 需要 5–10 年，LLM 安全用了不到 2 年。

原因很简单：**ChatGPT 让全世界人（包括审稿人）都在实际使用 LLM，安全的切肤之痛不再是抽象的。**

5 联邦学习：成熟期的阵痛

联邦学习是 TDSC 和 NDSS 上论文最多的方向，在 INFOCOM 2025 也有 23 篇之多。但值得注意的是两个信号：

信号一：从攻击转向实用防御。 2023 年的 FL 安全论文还在问「能攻击吗」（投毒、梯度泄露、后门），2025–2026 年已经在问「如何实用化防御」（拜占庭容错聚合、可验证低通信 FL、模型水印保护）。

信号二：融合成为新方向。 联邦学习不再孤立发展，而是与 LLM（联邦 LLM 微调 + FedLoRA）、强化学习（FedHPD）、视觉语言模型深度融合。ICML 2026 上，FedDTL 提出了解耦编码器训练 + RL 泛化微调的新范式。

信号三：在不同社区的温度差。 FL 在 USENIX 系列会议上几乎看不到，在 NSDI 2026 的论文列表中也缺席。这说明 FL 已经从「系统创新」转向「安全隐私」赛道——一个方向成熟之后，它在不同社区的「可见度」会分化。

思考

联邦学习的论文还很多，但「增量创新」的论文也越来越多。当一个方向的论文标题中反复出现「Robust」「Privacy-Preserving」「Efficient」这些修饰词，但是否真的解决了核心矛盾——隐私和效用的根本权衡——仍然有待回答。这可能是这个方向最大的长期挑战。

6 系统与网络：被 LLM 重塑的基础设施

6.1 从「传输比特」到「传输智能」

SIGCOMM 2024 的主题演讲可以概括为一句：网络不再是比特的管道，而是智能的血管。NSDI 2026 甚至把 session 命名为「All Your Networks Are Belong to ML」。

具体的重塑体现在三个层面：

训练层：GPU 通信成为核心瓶颈。 Crux（阿里云）通过 GPU 强度感知的通信调度减少争用；TE-CCL（UPenn+ 微软 + OpenAI）将 ML 集体通信建模为多商品流问题；Meta 分享了 RoCE 在大规模 AI 训练中的工业实践经验。当模型从千卡级扩展到万卡级，通信的开销从「重要」变成了「致命」。

推理层：KV Cache 驱动的全新系统设计。 CacheGen（SIGCOMM 2024）将 KV Cache 压缩 3.5–4.3 倍并通过网络流式传输；Sarathi-Serve（OSDI 2024）用 chunked-prefill 打破吞吐-延迟权衡；DroidSpeak（NSDI 2026）实现跨微调模型变体的 KV Cache 共享。KV Cache 不再是一个「缓存优化问题」，而是 LLM 推理系统设计的核心抽象。

边缘层：LLM 从云走向端。 INFOCOM 2025–2026 有超过 15 篇论文涉及 LLM 边缘

推理和量化调度。NSDI 2026 的 HydraServe（北大 + 阿里云）专门解决 Serverless LLM 的冷启动问题。MoVi（INFOCOM 2026）在移动设备上实现了实时多模态大模型交互式视频分析。这不是「可以把 LLM 放到边缘」，而是「LLM 必须到边缘才有商业模式」。

思考

一个有趣的观察：SIGCOMM 和 NSDI 上关于 LLM 基础设施的论文，大部分来自中国高校和企业——清华、北大、南大、上海 AI Lab、阿里云、华为、腾讯、蚂蚁。这暗示中国在 AI 基础设施层面的研究正在形成集群优势。相比之下，USENIX 系列会议上美国高校（Stanford、MIT、UC Berkeley、CMU）的论文更多聚焦在模型架构和安全层面。这是「基础设施」vs「上层建筑」的分工，还是碳基的另一个故事？

6.2 MoE：稀疏化带来的系统革命

Mixture-of-Experts（MoE）正在从一种「特殊的模型架构」变成「系统设计的核心输入」。SIGCOMM 2025 的 MixNet 专门为 MoE 的动态通信模式设计了可重构光电混合网络；NSDI 2026 的 SYMI（Stanford+NVIDIA+OpenAI）提出模型和优化器状态解耦的 MoE 训练方案；INFOCOM 的 SP-MoE 优化了 MoE 训练的流水线规划。

MoE 之所以特殊，是因为它引入了 **all-to-all 通信**——每个 token 需要被路由到不同的专家，而这种通信模式在传统网络架构中没有对应的优化方案。这是「算法驱动系统创新」的典型用例。

7 强化学习：从游戏玩家到 LLM 的「后训练引擎」

2024 年之前，强化学习在安全会议和系统会议上只是零星出现。但 ICML 2026 的数据揭示了一个惊人的事实：**强化学习以 886 篇论文成为 ICML 2026 的第一大方向**。

驱动力只有一个：RL 成为 LLM 后训练的标准范式。DeepSeek-R1 使用的 GRPO 方法引爆了整个 RL for LLM 领域——从 PPO 到 DPO 再到 GRPO，现在又衍生出 DAPO、GSPO、POPO、GOPO 等变体。ACM Digital Library 生动地描述了这个进化树。

A3C 获得 ICML 2026 Test of Time 奖绝非偶然——它发表于 2016 年的异步 RL 思想，十年后竟成为现代 LLM 后训练的基础设施。这种「技术回响」提醒我们：**基础研究的价值往往在十年后才能看清**。

思考

RL 从「让 Agent 学会玩游戏」到「让 LLM 学会推理」，这个转变的本质是什么？我认为是：RL 不再被当作「独立的学习范式」，而是被当作「在已有强先验模型上的微调工具」。LLM 提供了强大的世界知识和语言理解能力作为先验，RL 只需要在这个基础上做「对齐」和「增强」——问题从「从零学起」变成了「从 99 分学到 100 分」，而这恰恰是 RL 擅长的事。

8 Agent: 从「Chat」到「Act」的范式跃迁

如果说 LLM 的 1.0 版本是「聊天」，那么 2.0 版本无疑是「行动」。

NSDI 2026 专门出现了 Agent 相关的系统论文：Agentix（UC Berkeley+Google DeepMind）将 Agent 推理建模为通用程序的调度问题；Cortex（NUS+USTC+UofT）设计了 Agent 的语义感知知识缓存；SMetric（SJTU+阿里）实现了面向 Agent LLM Serving 的 Session 级别 KV Cache 管理。

ICML 2026 的 Cover Story 则揭示了更宏大的图景：AI Safety 以 114 篇论文成为第三大热门方向；扩散语言模型从理论走到实践；多模态 Agent（如密歇根大学的 Procedure-Aware Agent）从 VLM「看图说话」转向「持续感知 → 精准定位 → 驱动行动」的完整闭环。

思考

Agent 的兴起对系统研究提出了全新的挑战：Chatbot 的请求是「一次性的」，Agent 的请求是「session 级的」——需要维护长期记忆、工具调用状态、多步推理的中间结果。这意味着从 KV Cache 管理到调度策略到 SLO 定义，整个推理系统栈都需要重新设计。这也是为什么 NSDI 2026 的 Agent 论文标题中频繁出现「Session-Centric」「Semantic-Aware」「Program-Level」这些关键词。

9 跨领域「温差」现象

将 9 个会议/期刊并置观察，可以发现一个有趣的现象：同一个研究方向在不同社区之间存在显著的「温差」。

这个温差现象至少有两个启示：

第一，不要用一个社区的「热度」来判断一个方向的「价值」。联邦学习在 USENIX 几乎看不到，但在 TDSC 和 NDSS 上是顶流——这恰恰说明 FL 已经从「系统创新」沉淀为「安全隐私基础设施」，是一个成熟方向，而非衰退方向。

第二，「温差」本身就是机会。RWKV 在 ML 社区获得了 ICLR Oral 级别的认可，但

表 1: 同一方向在不同顶会的热度差异

研究方向	ML/AI 会议	安全会议	系统会议	网络会议
联邦学习安全	...		.	
LLM 推理系统	..	—		
LLM 安全/越狱	...		—	—
扩散模型		.	—	..
Mamba/SSM		—	..	—
KV Cache 优化	..	—		
Agent 系统		—		—

在网络/安全社区论文数量为零。如果一个架构声称自己有 $O(L)$ 推理复杂度、天然适合边缘部署，那么它迟早会与网络 and 系统社区的研究问题发生交集——谁先做，谁就能定义这个交叉领域的问题框架。

10 几点不成熟的思考

10.1 关于「热度」——警醒

读完这 500 多篇论文的标题和摘要，最大的感受不是「AI 发展真快」，而是「我们是否过度集中了」。

LLM 吞噬了一切。安全会议在讨论 LLM 越狱，系统会议在讨论 LLM 推理调度，网络会议在讨论 LLM 训练的通信优化，ML 会议在讨论 LLM 的后训练 RL。这当然说明 LLM 确实重要。但当一个社区的智力资源如此高度集中时，我们必须问自己：还有什么重要的问题，因为「不涉及 LLM」而被忽视？

后量子密码学、嵌入式安全、侧信道分析、形式化验证——这些方向在近年的顶会上越来越少出现，但它们解决的问题并没有消失。

10.2 关于「新旧交替」——警惕幸存者偏差

读到 CNN/RNN/LSTM 在所有会议中「消失」，自然会产生「它们过时了」的判断。但需要区分两种消失：

- (1) 因为它们被更优方案替代了（如 RNN 被 Transformer 在多数 NLP 任务上替代）；
- (2) 因为审稿人和作者觉得「不够新」而自我审查。

第(2)种消失是危险的。回看 2016–2017 年，当所有人都在追逐 GAN 和强化学习时，Transformer 在 NIPS 2017 上只是一篇 Oral 论文，远不是「统治一切」的存在。下一个范式转换的种子，可能正在我们现在忽视的方向上生长。

10.3 关于「交叉」——真正的创新在哪

最有价值的观察可能不是「什么方向最火」，而是「什么交叉正在发生」。

- **LLM × 联邦学习**：联邦 LLM 微调（LoRA+FL）正在将两个原本平行的领域缝合。FedDTL 在 ICML 2026 提出用 RL 做联邦 VLM 的泛化增强，说明这不仅是「把 LLM 放到 FL 框架里」，而是需要全新的方法。
- **LLM × 网络基础设施**：GPU 通信调度、光交换网络、可编程数据平面上的推理——网络研究正在从「传输层」走向「计算层」。SIGCOMM 正在从「网络会议」变成「AI 基础设施会议」。
- **LLM × 智能合约**：TDSC 上出现的用 LLM 检测智能合约漏洞（NAPO-SCVD）是 Web3 + AI 安全的一个新交叉点。这个方向还处于极早期，但两者都处于快速增长期。
- **RL × LLM 后训练**：这是 2026 年方法论层面最大的创新增量。PPO → DPO → GRPO → GSPO → POPO → GOPO 的进化路线，本质上是将 RL 从「从零学习」重新定义为「从强先验出发的精细优化」。

10.4 关于「中国角色」——不容忽视的集群效应

从论文的机构分布来看，中国高校和企业 AI 基础设施研究中的参与度极高。SIGCOMM 2025 上北大贡献了多篇 LLM 网络基础设施论文；NSDI 2026 上清华、北大、南大、SJTU 的论文密集出现；INFOCOM 上联邦学习和 LLM 边缘推理的论文大量来自中国团队。

这不是偶然。当美国的核心 AI 研究集中在 OpenAI、Anthropic、Google DeepMind 等少数几家顶级实验室时，中国的研究生态更加分布式——高校和企业并行推进，在基础设施层面形成了从芯片到网络到系统的完整研究栈。这可能是未来几年最值得关注的「结构性变化」。

写在最后

作为一个研究者，同时阅读 9 个不同社区的最新论文是一种奢侈。它让你跳出自己领域的「回音室」，看到更大的图景。

2023–2026 年这三年，AI 领域的最大变化不是某一个具体技术突破，而是 **LLM 作为一个「通用计算范式」的确立**。它不再是一个模型、一个方向、一个工具——它是一层新的抽象，就像操作系统是硬件的抽象一样，LLM 正在成为「智能」的抽象。

而在这个抽象之上，安全、系统、网络、应用、理论——所有计算机科学的传统领域都在被重新定义。这不是某个领域的「AI 化」，而是**整个计算机科学的「LLM-native 化」**。

对研究者而言，这个时代既是机会也是诱惑。机会在于，到处都是新问题；诱惑在于，很容易迷失在「热度」中而忘记了什么才是真正的科学问题。

希望这份报告能提供一些冷静的观察。

2026 年 7 月 16 日

A 数据来源说明

本报告基于以下数据源整理分析：

- **ACM Digital Library / ICML 2026:** 23,918 篇投稿，6,352 篇接收，录取率 26.6%。爬取关键词覆盖：深度学习、ML、RL、联邦学习、CNN、RNN、Transformer、LSTM、RWKV。
- **IEEE S&P 2023–2025:** 安全领域顶级会议。2025 年首次出现「LLM Security」专门 session。覆盖 50+ 篇 AI/ML 相关论文。
- **USENIX 系列 (Security, OSDI, ATC, NSDI) 2023–2026:** 系统与安全顶会。覆盖 LLM 推理系统、AI 安全攻击、隐私保护 ML 等方向。
- **SIGCOMM 2023–2025:** 网络领域顶会。2024 年开始出现「Moving bits for AI」等 AI 专题 session。录取率约 16%。
- **INFOCOM 2025–2026:** 网络领域顶会。2025: 272/1458 篇 (18.7%), 2026: 329/1740 篇 (18.9%)。
- **NDSS 2023–2025:** 网络安全顶会。覆盖联邦学习安全、LLM 安全、对抗攻击、深度伪造等方向。
- **TDSC 2025–2026:** IEEE 安全与可靠计算汇刊。覆盖 46+ 篇 AI/ML 论文，联邦学习和后门攻击为最热门方向。
- **NSDI 2026:** 系统顶会。Spring 接受率 24.2% (50/207)，Fall 接受率 22.1% (100/452)。